Práctica 2

Análisis Exploratorio de Datos y Preprocesamiento

Laboratorio de Inteligencia Artificial – Curso 2026-2027

Fecha de publicación: 19 de octubre
Entrega: martes 10 o jueves 12 de noviembre antes de la clase de prácticas.
Examen: martes 10 o jueves 12 de noviembre durante la clase de prácticas.

Introducción

En esta práctica vamos a utilizar un conjunto de datos que describe la venta de propiedades residenciales individuales en Ames (Iowa, USA) desde 2006 hasta 2010. El conjunto de entrenamiento contiene 1460 observaciones y un gran número de variables explicativas (23 nominales, 23 ordinales, 14 discretas y 20 continuas) involucradas en la evaluación del valor de las viviendas. La información sobre cada una de las variables la puedes encontrar en el fichero data-description.txt, subido a Moodle junto con el resto de información necesaria para realizar la práctica.

El objetivo de la práctica es realizar una serie de tareas de **limpieza y preprocesado** en el conjunto de datos, a fin de dejarlo en un estado óptimo para la creación posterior de modelos de regresión. También es importante que el notebook de entrega recoja todas las argumentaciones y reflexiones que hagáis, ya que en el trabajo de análisis de datos tan importante es la codificación como la **explicación** y la exposición de resultados y procesos.

Método de entrega

Las prácticas se harán por parejas. Cada envío debe constar de un único archivo zip llamado **p2_gggg_mm_apellido1_apellido2.zip**, donde gggg es el número de vuestro grupo de laboratorio y mm el identificador asignado a cada persona/pareja en este grupo. Este archivo zip debe enviarse a través de Moodle. Es importante, siempre, poner los nombres de los autores y el número del grupo de prácticas en todos los archivos que envíes.

Material a entregar

El fichero zip a entregar debe incluir:

- El *código* y la *memoria* de la práctica en formato **notebook** de Python (ipynb). Si habéis desarrollado ficheros adicionales (por ejemplo, para realizar pruebas adicionales o análisis complementarios), debéis documentarlos e indicarlos en la memoria y en un fichero README.txt.
- Se recomienda que los resultados o comparaciones incluidas se muestren **en forma de tablas o gráficas**.

Calificación

La práctica se evaluará en un rango de 0-10, donde se tendrá en cuenta tanto la memoria como el código entregado (50%) y el examen (50%) presencial el día de la entrega, con una nota mínima (4) en cada parte.

Deshonestidad académica: Comprobaremos vuestro código con otras entregas en la clase para verificar la redundancia lógica. Si copiáis el código de otra entrega y lo enviáis con cambios menores, lo sabremos. Estos detectores de trampas son bastante difíciles de engañar, así que no lo intentéis. Confiamos en que todos vosotros enviareis únicamente vuestro propio trabajo; *por favor* no nos defraudéis. Si lo hacéis, utilizaremos los recursos disponibles más severos.

Obtener ayuda: ¡No estás solo! Si os encontráis atascados en algo, comunicádnoslo a los profesores para poder obtener ayuda.

GUIÓN

A partir de la descripción de los datos (data-description.txt) y el fichero de datos (data.csv) que puedes encontrar en Moodle, realiza las siguientes tareas.

1. Importa las librerías adecuadas: numpy, pandas, matplotlib, seaborn.
2. Carga los datos con la función **read_csv** de pandas y visualiza las primeras filas. Después, muestra los tipos de las columnas.
3. ¿Cuántas viviendas hay en el conjunto de datos? Muestra las variables, si las hay, que tienen valores nulos e indica cuántos nulos tiene cada una de ellas.
4. Realiza un estudio individual de las siguientes variables del conjunto de datos:
    - id
    - MSSubClass
    - MSZoning
    - LotFrontage
    - LotArea
    - Street
    - Alley
    - LotShape
    - LandContour
    - Utilities
    - LandSlope
    - Neighborhood
    - YearBuilt
    - YearRemodAdd
    - GarageCars, GarageArea, GarageQual, GarageCond, GarageType, GarageYrBlt, GarageFinish (se recomienda analizarlas en conjunto)
    - OverallQual
    - OverallCond
    - SalePrice

    En cada caso:

    - Identifica valores únicos de la columna
    - El tipo (categórica sin orden, categórica con orden, discreto o continuo).
    - Si hay valores nulos o no (puedes utilizar la salida de la pregunta 3 o buscar específicamente en la columna a tratar).
    - En caso de que la columna tenga valores nulos, el tratamiento que se te ocurre para trabajar con ellos.
    - Si la columna es numérica obtén valores mínimo y máximo; estudia si hay outliers.
    - Especifica si decides o no eliminar la columna, porque su aportación puede ser irrelevante en procesos de modelado posteriores.

- Si es necesaria una recodificación de la columna, por ser categórica u otra razón, explica por qué se hace esta conversión y qué método empleas para llevarla a cabo.

El objetivo de este estudio de las variables es preparar el conjunto de datos para que pueda ser tratado posteriormente en modelos de Machine Learning.

Sugerencia: comprueba si los valores de las columnas descritos en el fichero data-description.txt coinciden con los que observamos experimentalmente al ir tratando dichas columnas.

5. Ahora que has realizado algunas operaciones sobre las columnas anteriores, vamos a comprobar algunas estadísticas simples. Por ejemplo:
   - Comprueba el número de casas. ¿Ha variado respecto del que calculaste en la pregunta 3?
   - Comprueba de nuevo el número de valores nulos de las columnas. ¿Ha variado respecto al que obtuviste en la pregunta 3? Para facilitar esta respuesta rellena una tabla como la siguiente:

Columna	#Missing values anteriores	#Missing values actual

6. Muestra un histograma de las variables LotFrontage, LotArea, SalePrice, OveralQual y comenta los resultados.
   Crea un gráfico de donut para variables categóricas como LandSlope y, Neighborhood.
   Ayuda: un gráfico de donut es un gráfico de tarta quitando la parte central. Ejemplo de cómo obtenerlo:

```
import matplotlib.pyplot as plt
plt.pie([100, 300, 50], labels=["Mesas", "Sillas", "Armarios"])
my_circle=plt.Circle((0,0), 0.7, color='white')
p=plt.gcf()
p.gca().add_artist(my_circle)
```

   A la vista de los resultados, ¿qué decisiones tomarías sobre estas tres variables?
   Sugerencia: En los dos casos puede serte útil revisar el significado de estas columnas en el fichero data-description.txt

7. Para finalizar, estudia la correlación entre las variables numéricas del dataset. Calcula la matriz de correlación de estas variables y muéstrala con la función **clustermap** de la librería seaborn. Comenta los resultados.